Міністерство освіти і науки України
Державний університет «Житомирська політехніка»

Кафедра КТуМтаТ
Група ІВ-25-1

Теорія ймовірностей і математична статистика

Практична робота № 7–8

«Формула повної ймовірності та формула Байєса в ймовірнісній класифікації та діагностиці програмних систем»

Варіант 1

Перевірив: Лисенко М. С.
Виконав: Римаренко Є. О.

Житомир 2026

					ТЙМС.ІВ-25-1.ПР7-8		
Змн.	Арк.	№ докум.	Підпис	Дата			
Розроб.		Римаренко Є.О.			Звіт з практичної роботи № 7–8	Літ.	Арк. 1 / Аркушів 10
Перевір.		Лисенко М. С.					
Керівник						ФІКТ, гр. ІВ-25-1	
Н. контр.							
Затверд.							

1 Мета та постановка завдання

Мета роботи — застосувати формулу повної ймовірності та формулу Байєса для аналізу гіпотез, змоделювати переоцінку ймовірностей і реалізувати простий наївний байєсівський класифікатор.

У блоці 1 потрібно змоделювати виявлення атак для п’яти обсягів вибірки та побудувати графік збіжності. У блоці 2 за варіантом 1 потрібно знайти ймовірність збою й визначити його джерело серед трьох серверів. У блоках 3 і 4 потрібно класифікувати повідомлення за двома та трьома бінарними ознаками й порівняти прогноз із фактичним класом.

2 Математична модель

Гіпотези H_1, H_2, … утворюють повну групу: вони несумісні, а сума їхніх апріорних ймовірностей дорівнює одиниці. Після появи ознаки A ймовірності гіпотез перераховуються за формулою Байєса.

$$P(A) = \Sigma_i P(H_i)P(A|H_i)$$

$$P(H_k|A) = (P(H_k)P(A|H_k))/(P(A))$$

Блок 1 Байєсівське оновлення

Частки легітимних користувачів, ботів і атак дорівнюють 0,90; 0,08; 0,02. Імовірності ознаки A для цих категорій: 0,01; 0,25; 0,90.

$$P(A) = 0{,}90 \cdot 0{,}01 + 0{,}08 \cdot 0{,}25 + 0{,}02 \cdot 0{,}90 = 0{,}047$$

$$P(H_3|A) = (0{,}018)/(0{,}047) \approx 0{,}382979$$

Інші апостеріорні ймовірності: $P(H_1|A) \approx 0{,}191489$ і $P(H_2|A) \approx 0{,}425532$. Їхня сума разом із $P(H_3|A)$ дорівнює одиниці.

Блок 2 Локалізація джерела збоїв

Запит надходить на сервери S_1, S_2, S_3 з імовірностями 0,50; 0,30; 0,20. Умовні ймовірності збою F: 0,01; 0,03; 0,10.

$$P(F) = 0{,}50 \cdot 0{,}01 + 0{,}30 \cdot 0{,}03 + 0{,}20 \cdot 0{,}10 = 0{,}034$$

$$P(S_3|F) = (0{,}020)/(0{,}034) \approx 0{,}588235$$

Блок 3 Класифікатор із двома ознаками

Фактичний клас повідомлення — Spam або Ham. Частка спаму становить 0,30. Ознаки x_1 та x_2 показують наявність слів free і click: 1 — слово є, 0 — слова немає. Ознаки вважаються незалежними за умови відомого класу.

$$s(C|X) = P(C) \cdot \prod_j P(w_j|C)^{x_j}(1 - P(w_j|C))^{1-x_j}$$

$$P(\text{Spam}|X) = (s(\text{Spam}|X))/(s(\text{Spam}|X) + s(\text{Ham}|X))$$

Якщо $P(\text{Spam}|X) \geq 0{,}5$, прогнозується Spam; інакше — Ham. Умовні ймовірності наявності слів задано в таблиці 1. Імовірність відсутності слова дорівнює одиниці мінус імовірність його наявності.

Таблиця 1 — Параметри двох ознак

Слово	P(w|Spam)	P(w|Ham)
free	0,80	0,05
click	0,60	0,10

Параметри класів задані умовою, тому навчання на вибірці та згладжування Лапласа тут не виконуються. Генерується незалежна тестова вибірка за заданою моделлю.

Блок 4 Детекція спаму за трьома словами

За варіантом 1 частка спаму дорівнює 0,20, частка звичайних листів — 0,80. Використано три бінарні ознаки та той самий спосіб нормування байєсівських оцінок, що й у блоці 3.

Умова не задає ймовірностей слів. Для числового експерименту прийнято додаткові параметри таблиці 2 та умовну незалежність ознак. Перші дві пари ймовірностей взято з блоку 3. Слово win і третю пару ймовірностей обрано для навчальної моделі.

Таблиця 2 — Додаткові параметри моделі блоку 4

Ознака	Слово	P(w|Spam)	P(w|Ham)
w_1	free	0,80	0,05
w_2	click	0,60	0,10
w_3	win	0,70	0,05

Для листа з усіма трьома словами X = (1, 1, 1) ненормовані оцінки становлять:

$$s(Spam|111) = 0{,}20 \cdot 0{,}80 \cdot 0{,}60 \cdot 0{,}70 = 0{,}0672$$

$$s(Ham|111) = 0{,}80 \cdot 0{,}05 \cdot 0{,}10 \cdot 0{,}05 = 0{,}0002$$

$$P(Spam|111) = (0{,}0672)/(0{,}0674) \approx 0{,}997033$$

Така оцінка є ймовірністю класу для заданої комбінації ознак, а не загальною точністю класифікатора. Для перевірки моделі генерується 100 000 листів зі збереженням їхнього фактичного класу.

Статистична частота для кожної комбінації X обчислюється серед листів саме з цією комбінацією. Абсолютна похибка дорівнює модулю різниці між частотою та теоретичною апостеріорною ймовірністю.

3 Опис програмної реалізації

Програму реалізовано мовою Python. Модуль random генерує випадкові класи та ознаки, pathlib визначає шляхи до файлів, matplotlib будує графіки. Результати виводяться в термінал. Кожен блок міститься в окремому файлі; main.py запускає їх послідовно.

У блоці 1 спочатку обирається категорія запиту, а потім незалежним випадковим числом перевіряється ознака A. Частота атаки визначається лише серед запитів з ознакою A.

```
if count_a > 0:
    frequency_attack = count_attack_a / count_a
    error_attack = abs(frequency_attack - probability_attack)
```

У блоці 2 так само обирається сервер і перевіряється збій. Лічильники збоїв для серверів дають змогу оцінити умовні частоти їхнього вибору.

```
if rng.random() < error_chances[server]:
    count_errors += 1
    errors_by_server[server] += 1
```

У блоках 3 і 4 функція posterior перемножує ймовірності наявності або відсутності ознак та нормує дві оцінки класів. Спільні функції розрахунку метрик і побудови матриці імпортуються з block3.py.

```
if features[index] == 1:
    score_spam *= chances_spam[index]
    score_ham *= chances_ham[index]
else:
    score_spam *= 1 - chances_spam[index]
    score_ham *= 1 - chances_ham[index]
```

Для повторюваності використано окремі зерна 101–104. Усі наведені результати фактично отримано під час запуску в середовищі Python 3.14.7 з matplotlib 3.11.2. Установлення залежностей і запуск описано в README.

Репозиторій: https://github.com/gjn9429-oss/pr4-bayes-classification

4 Результати експериментів

Блок 1 Збіжність байєсівської оцінки

Теоретичні значення: P(A) = 0,047; P(H₃|A) ≈ 0,382979. Для кожного N згенеровано окрему вибірку. Результати наведено в таблиці 3.

Таблиця 3 — Частоти ознаки A та атак серед запитів з A

N	M(A)	W(A)	W(H₃|A)	Абсолютна похибка
100	0	0,000000	не визначено	—
1 000	54	0,054000	0,259259	0,123719
10 000	428	0,042800	0,355140	0,027839
100 000	4 612	0,046120	0,386600	0,003621
1 000 000	47 018	0,047018	0,378663	0,004315

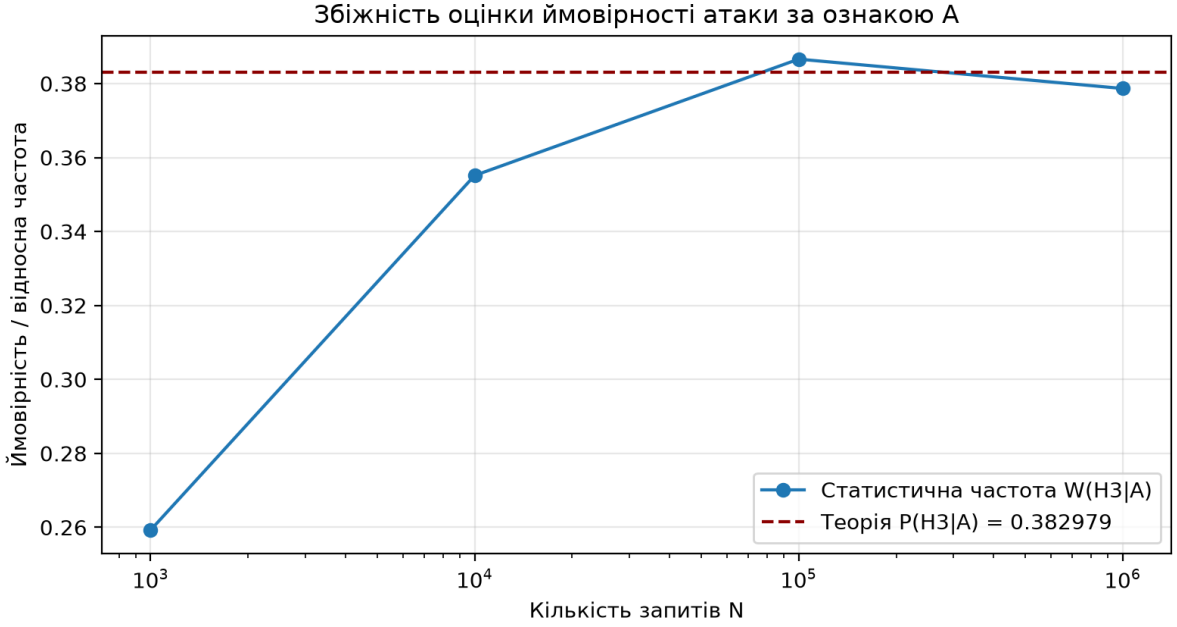


Рисунок 1 — Збіжність частоти атаки за наявності ознаки A

При N = 100 ознака A не виникла, тому умовну частоту неможливо обчислити. Така подія можлива: імовірність відсутності A у 100 запитах дорівнює $0{,}953^{100} \approx 0{,}00812$. Цю точку на графіку пропущено.

Для N = 1 000 000 отримано W(H₃|A) ≈ 0,378663 з абсолютною похибкою 0,004315. Похибка окремих випадкових вибірок не зобов'язана зменшуватися монотонно.

Блок 2 Локалізація збоїв серед серверів

У 100 000 запитах зафіксовано 3 382 збої. Із них на S_1 припало 493, на S_2 — 932, на S_3 — 1 957. Теоретичні та статистичні значення наведено в таблиці 4.

Таблиця 4 — Порівняння ймовірностей і частот

Подія	Теорія	Частота	Похибка
P(F)	0,034000	0,033820	0,000180
P(S1|F)	0,147059	0,145772	0,001287
P(S2|F)	0,264706	0,275577	0,010871
P(S3|F)	0,588235	0,578652	0,009584

Хоча сервер S_3 обробляє лише 20% запитів, його умовна частка серед збоїв теоретично становить близько 58,82%. Причина — вища ймовірність помилки на цьому сервері. У симуляції отримано 57,87%.

Блок 3 Класифікація за двома словами

Таблиця 5 містить усі чотири комбінації ознак. За заданими параметрами рішення збігається з перевіркою наявності слова free: комбінації 10 і 11 відносяться до Spam, 00 і 01 — до Ham.

Таблиця 5 — Теоретичні апостеріорні ймовірності

x_1	x_2	P(Spam|X)	Прогноз
0	0	0,038554	Ham
0	1	0,351220	Ham
1	0	0,752941	Spam
1	1	0,976271	Spam

У тестовій вибірці з 10 000 повідомлень отримано TP = 2 360, FP = 370, TN = 6 683, FN = 587. Spam прийнято за позитивний клас. FP — звичайний лист, помилково позначений як спам; FN — пропущений спам.

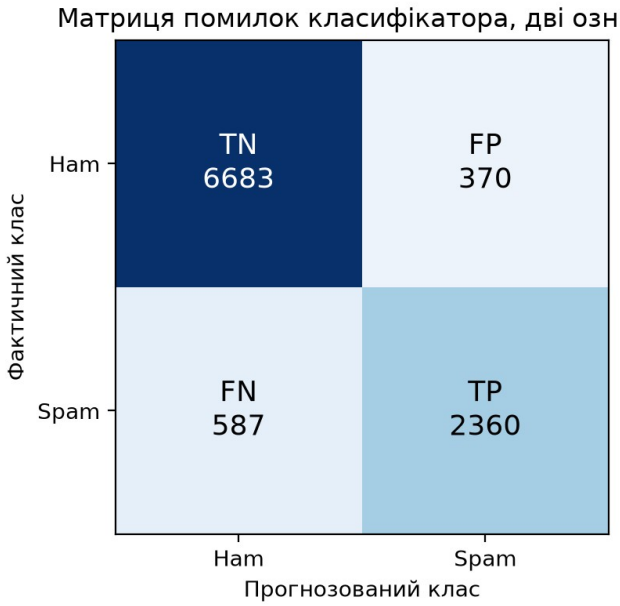


Рисунок 2 — Матриця помилок класифікатора з двома ознаками

Таблиця 6 — Метрики класифікатора блоку 3

Метрика	Теоретично	Експеримент
Accuracy	0,905000	0,904300
Precision	0,872727	0,864469
Recall	0,800000	0,800814
F1	0,834783	0,831425

$$\text{Accuracy} = (TP + TN) / N; \quad \text{Precision} = TP / (TP + FP)$$

$$\text{Recall} = TP / (TP + FN); \quad F1 = 2TP / (2TP + FP + FN)$$

Загальна точність дорівнює 90,43%. Серед позначених як Spam листів близько 86,45% справді є спамом. Повнота 80,08% показує частку виявленого спаму. Теоретичні метрики перевірено перебором усіх комбінацій ознак.

Блок 4 Класифікація за трьома словами

Для кожної комбінації ознак порівняно теоретичну апостеріорну ймовірність із фактичною часткою спаму серед згенерованих листів цієї групи. Використано 100 000 симуляцій та додаткові параметри таблиці 2.

Таблиця 7 — Апостеріорні ймовірності та частоти спаму

X	Листів	P(Spam|X)	W(Spam|X)	Похибка
000	65 699	0,007333	0,007428	0,000095
001	4 516	0,246696	0,241807	0,004889
010	7 877	0,090680	0,090009	0,000671
011	2 064	0,815534	0,825097	0,009563
100	5 443	0,359551	0,367812	0,008261
101	4 557	0,961373	0,963353	0,001980
110	3 245	0,883436	0,881048	0,002388
111	6 599	0,997033	0,996515	0,000518

Для комбінації 111 отримано 6 599 листів, із яких 6 576 справді належать до Spam. Частота 0,996515 близька до теоретичного значення 0,997033. Абсолютна похибка становить 0,000518.

Класифікатор прогнозує Spam для 011, 101, 110 і 111. Для інших комбінацій прогнозується Ham. Імовірність конкретного класу не є гарантією правильного рішення для кожного окремого листа.

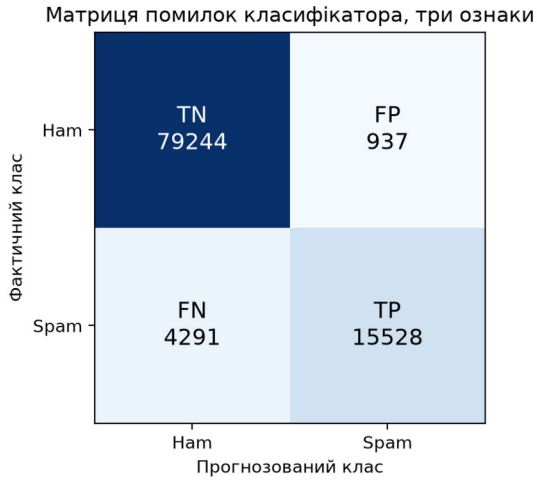


Рисунок 3 — Матриця помилок класифікатора з трьома ознаками

Таблиця 8 — Метрики класифікатора блоку 4

Метрика	Теоретично	Експеримент
Accuracy	0,948000	0,947720
Precision	0,942584	0,943091
Recall	0,788000	0,783491
F1	0,858388	0,855914

Отримано TP = 15 528, FP = 937, TN = 79 244, FN = 4 291. Точність становить 94,772%, повнота — 78,349%. Це характеристики прийнятої моделі. Різницю з блоком 3 не можна пояснити лише третьою ознакою: частку спаму також змінено з 0,30 до 0,20.

5 Висновки

У роботі застосовано формули повної ймовірності та Байєса для переоцінки гіпотез. Для системи виявлення атак знайдено P(A) = 0,047 та $P(H_3|A) \approx 0{,}382979$. Симуляція показала близькі частоти для великих вибірок і випадкові коливання похибки.

Для трьох серверів отримано P(F) = 0,034 і $P(S_3|F) \approx 0{,}588235$. Реалізовано класифікатори з двома й трьома ознаками, побудовано матриці помилок та обчислено метрики. Експериментальні оцінки узгоджуються з теорією для заданих моделей. Код поділено на блоки, таблиці наведено у звіті, а графіки збережено в папці graphics.